

EBOOK — Engenharia de Prompt e Melhores Práticas

1. O que é Prompting?

Prompting é o processo de instruir um modelo de linguagem para produzir a resposta desejada. Ele combina técnica, estratégia e clareza — quase como programar usando linguagem natural.

Enquanto um comando fraco produz respostas vagas, um prompt bem projetado libera todo o potencial do modelo, elevando a precisão, consistência e qualidade dos outputs.

1.1. Por que o prompting é tão importante?

Modelos de linguagem são profundamente sensíveis à forma como recebem instruções. Mudanças pequenas no wording podem alterar completamente o raciocínio da IA.

A engenharia de prompt é, portanto, uma habilidade essencial para:

- aumentar a confiabilidade das respostas;
 - reduzir erros e alucinações; - controlar tom, estilo e formato;
 - orientar raciocínio passo a passo; - ensinar tarefas específicas sem necessidade de fine-tuning.
-

2. Principais Técnicas de Prompting

O slide apresenta quatro categorias essenciais: **Zero-shot**, **Few-shot**, **Chain of Thought** e técnicas avançadas como **Tree of Thought**, além do uso de parâmetros de controle.

Aqui, detalhamos cada uma em profundidade.

3. Zero-Shot Prompting

3.1. O que é?

É o prompting **sem fornecer nenhum exemplo**. O modelo baseia sua resposta exclusivamente no conhecimento aprendido durante o pré-treinamento.

3.2. Quando usar?

- Perguntas diretas e factuais.
- Consultas simples e tarefas de baixa ambiguidade.
- Casos em que a resposta esperada é evidente.

3.3. Pontos fortes:

- Rápido e econômico em tokens.
- Ideal para explorações iniciais.
- Bom para tarefas amplas como tradução simples ou classificação binária.

3.4. Limitações:

- Menor precisão em tarefas complexas.
- Propenso a interpretações erradas quando há ambiguidade.

3.5. Exemplo aprofundado:

Prompt: “Explique o conceito de produtividade marginal.”

Aqui, o modelo usa seu conhecimento geral, mas pode errar nuances sem exemplos.

4. Few-Shot Prompting

4.1. O que é?

É a técnica de enviar **exemplos antes da tarefa principal**. Esses exemplos funcionam como mini-demonstrações que instruem o modelo sobre formato, estilo, lógica e consistência esperado.

4.2. Por que funciona?

LLMs são treinados com aprendizado autorregressivo, então quando recebem exemplos, eles **imitam padrões estruturais, semânticos e lógicos** fornecidos.

4.3. Como usar bem:

1. **Escolha exemplos representativos:** Não coloque exceções. Use padrões típicos.
2. **Seja consistente:** Mesmo formato, mesmo estilo.
3. **Evite exemplos demais:** 2–5 exemplos é o ideal.
4. **Dê a tarefa final separadamente:** Isso evita confusões.

4.4. Quando aplicar Few-shot?

- Classificação com múltiplas categorias.
- Tarefas criativas (poemas, roteiros, resumos estilizados).
- Tradução contextual.
- Extração de informações complexas.

4.5. Exemplo aprofundado:

Você pode treinar o modelo para seguir seu estilo de escrita profissional, fornecendo exemplos reais seus.

5. Chain of Thought (CoT)

5.1. O que é?

CoT orienta o modelo a **mostrar o raciocínio passo a passo** antes da resposta final.

5.2. Por que é tão poderoso?

Porque modelos avançados raciocinam melhor quando são incentivados a explicitar suas etapas internas.

5.3. Quando usar CoT?

- Matemática e lógica.
- Problemas com múltiplas etapas.

- Planejamento.
- Teses argumentativas.

5.4. Estrutura típica:

1. Apresentação do problema.
2. Solicitação explícita do raciocínio.
3. Resposta fundamentada.

5.5. Exemplo comentado:

Prompt:

“Um trem parte às 14h, percorre 150 km em 2 horas e depois segue por mais 100 km a 50 km/h. Que horas chega? Explique passo a passo.”

Com CoT, o modelo destrincha tempo, velocidades e soma final.

6. Zero-Shot CoT

6.1. Como funciona?

Em vez de exemplos, basta adicionar uma frase-gatilho como: - “Vamos pensar passo a passo.” - “Explique seu raciocínio.” - “Raciocine antes de responder.”

6.2. Benefícios:

- Não precisa de exemplos.
- Reduz tokens.
- Surpreendentemente eficaz em modelos avançados.

6.3. Limitações:

- Pode gerar raciocínio prolixo demais.
 - Alguns modelos ainda desviam do caminho ideal.
-

7. Tree of Thought (ToT)

7.1. O que é?

ToT conduz o modelo a explorar **múltiplos caminhos de raciocínio**, como uma árvore de possibilidades.

7.2. Como opera:

- O modelo gera várias soluções parciais.
- Avalia prós e contras de cada uma.
- Escolhe a solução mais adequada.

7.3. Para que serve:

- Problemas criativos complexos.
- Resolução de desafios com vários caminhos possíveis.
- Análise de cenários e simulações.

7.4. Exemplo:

Criar estratégias alternativas de marketing e então avaliar qual tem melhor custo-benefício.

8. Controle de Parâmetros do Modelo

Modelos modernos possuem ajustes que influenciam enormemente o estilo da resposta.

8.1. Temperatura

Controla aleatoriedade.

- **Baixa (0.1–0.3):** Respostas precisas, técnicas, pouco variáveis.
- **Alta (0.7–1.0):** Respostas criativas, variadas e imprevisíveis.

8.2. Tokens máximos

Define o tamanho da resposta.

- Útil para limitar ou expandir a profundidade.

8.3. Top-P (Nucleus Sampling)

Seleciona tokens dentro de um percentual de probabilidade cumulativa. É uma forma mais refinada de controlar criatividade.

8.4. Frequência e presença penalty

Evita repetições e força o modelo a explorar novos termos.

9. Uso Estratégico de Delimitadores

Delimitadores ajudam a separar partes do prompt e reduzir ambiguidades. Podem ser:

- """"
- ---
- ###
- <contexto>

9.1. Por que funcionam tão bem?

Modelos leem prompts como texto linear. Delimitadores funcionam como “metamarcadores” que deixam claro o que é:

- instrução,
- exemplo,
- contexto,
- tarefa final.

9.2. Exemplo:

INSTRUÇÃO

Explique o conceito de demanda agregada.

CONTEXTO

Aluno de economia.

10. Estruturando Instruções: Boas Práticas Essenciais

10.1. Clareza

Evite ambiguidade. Diga explicitamente o que deseja.

10.2. Contexto

Forneça tudo que o modelo precisa saber antes da tarefa.

10.3. Limitação de escopo

Ajuda a manter foco e precisão.

10.4. Exemplos representativos

Mostram exatamente o padrão esperado.

10.5. Tom e formato

Peça explicitamente: lista, tabela, parágrafo, número de itens, estilo formal etc.

11. Template Completo de Prompt Estruturado

INSTRUÇÃO

[Descrição da tarefa]

EXEMPLOS

Exemplo 1: [input] → [output]

Exemplo 2: [input] → [output]

CONTEXTO

[Informações adicionais]

TAREFA

[Novo input que deve ser processado]

12. Casos Reais e Estratégias de Alta Performance

12.1. Zero-shot para rapidez

Perguntas diretas, como consulta a fatos.

12.2. Few-shot para ambiguidade

Reduz 60% de erros quando bem aplicado.

12.3. CoT para precisão

Melhora 300% a qualidade de raciocínio em problemas analíticos.

13. Conclusão

Dominar prompting é dominar a porta de entrada para o potencial verdadeiro da IA.

Quem aprende a fazer as perguntas certas consegue transformar modelos de linguagem em copilotos poderosos para:

- produtividade,
- criatividade,
- pesquisa,
- ensino,
- desenvolvimento profissional.

O futuro pertence a quem domina o diálogo com a IA.

REFERÊNCIAS

- BROWN, T. et al. “Language Models are Few-Shot Learners” (2020).
- Prompting Techniques | Prompt Engineering Guide
- WEI, J. et al. “Chain of Thought Prompting Elicits Reasoning in Large Language Models” (2022).
- Engenharia de Contexto: Email de Vendas com IA
- Engenharia de Prompt (Alex Souza)